



FACULDADE DE TECNOLOGIA DA ZONA LESTE

SABRINA CARVALHO DA SILVA
SARA FELIX SOUZA

Extração, Transformação e Carregamento de Dados como Recurso
para Validação de Informações: Um estudo de caso dos dados
disponibilizados por meio do DATASUS

São Paulo

2025



FACULDADE DE TECNOLOGIA DA ZONA LESTE

SABRINA CARVALHO DA SILVA

SARA FELIX SOUZA

Extração, Transformação e Carregamento de Dados como Recurso
para Validação de Informações: Um estudo de caso dos dados
disponibilizados por meio do DATASUS

Trabalho de Conclusão de Curso apresentado à Faculdade de Tecnologia da Zona Leste, sob a orientação do Professor Doutor Leandro Colevati dos Santos, como requisito parcial para obtenção do diploma de Graduação no Curso de Análise e Desenvolvimento de Sistemas.

São Paulo

2025

SILVA, Sabrina Carvalho

SOUZA, Sara Felix

Extração, Transformação e Carregamento de Dados como Recurso para Validação
de Informações: Um estudo de caso dos dados disponibilizados por meio do
DATASUS. / Sabrina Carvalho da Silva/ Sara Felix Souza

São Paulo, 2025

54p.

Orientador: Prof. Dr. Leandro Colevati dos Santos

Trabalho de Conclusão de Curso de Graduação. Faculdade de Tecnologia da Zona
Leste - SP, Curso Superior de Tecnologia em Análise e Desenvolvimento de
Sistemas.

1.Coronavirus. 2.Covid-19. 3.Processo ETL. 4.Fake News. 5.Dataset



FACULDADE DE TECNOLOGIA DA ZONA LESTE

SABRINA CARVALHO DA SILVA

SARA FELIX SOUZA

Extração, Transformação e Carregamento de Dados como Recurso
para Validação de Informações: Um estudo de caso dos dados
disponibilizados por meio do DATASUS

Monografia apresentada no curso de Tecnologia em
Análise e Desenvolvimento de Sistemas na Faculdade
de Tecnologia da Zona Leste como requerido parcial
para obter o título de Tecnólogo em Análise e
Desenvolvimento de Sistemas.

Aprovado em:

Banca Examinadora

Orientador: Prof. Dr. Leandro Colevati dos Santos / Instituição: Fatec-ZL

Julgamento: _____ Assinatura: _____

São Paulo, 12 de dezembro de 2025.

DEDICATÓRIA

É com muito pesar, que dedicamos este trabalho àqueles que, por infelicidade do destino, encontraram seu fim na pandemia. Aos que ainda estão aqui, que diariamente procuram conforto nas lembranças dos que se foram – caminhos para superar e esquecer tamanho sofrimento – nossos sentimentos.

AGRADECIMENTOS

Gostaríamos de expressar nossos agradecimentos à instituição de ensino e aos docentes envolvidos na nossa formação acadêmica. Ao nosso orientador, pelo suporte técnico, acadêmico e pelas valiosas contribuições para este trabalho. Às nossas famílias e amigos, que foram nossos portos seguros durante esta trajetória. A todos que, direta ou indiretamente, colaboraram para a realização desta monografia, muito obrigado(a).

SILVA, Sabrina Carvalho; SOUZA, Sara Felix; **Extração, Transformação e Carregamento de Dados como Recurso para Validação de Informações: Um estudo de caso dos dados disponibilizados por meio do DATASUS**. 53p. Trabalho de conclusão de curso de graduação, Faculdade de Tecnologia da Zona Leste.

RESUMO

A pandemia da COVID-19 evidenciou a importância da análise de dados como ferramenta de enfrentamento a crises sanitárias e combate à desinformação. No Brasil, o avanço da doença foi acompanhado pela propagação de fake news, dificultando o acesso da população a informações confiáveis. Diante desse cenário, este trabalho teve como objetivo compreender como o tratamento e a organização das informações podem gerar conhecimento útil e acessível.

O objetivo principal foi demonstrar, por meio do uso dos processos ETL e KDD, a importância da extração, transformação e carregamento de dados para a realização de análises confiáveis, entendidas neste trabalho como análises baseadas em dados consistentes, padronizados, provenientes de fontes oficiais e submetidos a critérios de validação e tratamento que asseguram sua integridade e coerência, culminando no desenvolvimento do dashboard “Painel Coronavírus Brasil”, criado no Microsoft Power BI.

A pesquisa, de natureza bibliográfica e exploratória, utilizou bases públicas e ferramentas de análise para gerar indicadores como mortalidade, incidência, casos e óbitos novos e confirmados, possibilitando filtragens por estado, ano e região.

Os resultados evidenciam que a correta estruturação dos dados permite validar informações e distinguir conteúdos verdadeiros de notícias falsas. Conclui-se que o processo ETL, aliado ao KDD e a ferramentas de Dataviz, constituem um meio eficaz para transformar grandes volumes de dados brutos em informações verificáveis e visualmente compreensíveis, fortalecendo a transparência e a gestão pública baseada em evidências.

Palavras-chave: DATASUS. Covid-19. Processo ETL. Processo KDD. Fake News. Dataviz.

SILVA, Sabrina Carvalho; SOUZA, Sara Felix; **Data Extraction, Transformation, and Loading as a Resource for Information Validation: A case study of data made available through DATASUS**. 53p. Undergraduate thesis, Faculdade de Tecnologia da Zona Leste.

ABSTRACT

The COVID-19 pandemic highlighted the importance of data analysis as a tool for coping with health crises and combating misinformation. In Brazil, the spread of the disease was accompanied by the propagation of fake news, hindering the population's access to reliable information. Given this scenario, this work aimed to understand how the treatment and organization of information can generate useful and accessible knowledge.

The main objective was to demonstrate, through the use of ETL and KDD processes, the importance of data extraction, transformation, and loading for conducting reliable analyses, understood in this work as analyses based on consistent, standardized data from official sources and subjected to validation and treatment criteria that ensure their integrity and coherence, culminating in the development of the "Coronavirus Brazil Panel" dashboard, created in Microsoft Power BI.

The research, of a bibliographic and exploratory nature, used public databases and analysis tools to generate indicators such as mortality, incidence, new and confirmed cases and deaths, allowing filtering by state, year, and region. The results show that the correct structuring of data allows for the validation of information and the distinction between true content and fake news. It is concluded that the ETL process, combined with KDD and Dataviz tools, constitutes an effective means of transforming large volumes of raw data into verifiable and visually understandable information, strengthening transparency and evidence-based public management.

Keywords: DATASUS. COVID-19. ETL Process. KDD Process. Fake News. Dataviz.

LISTA DE FIGURAS

Figura 1 – Processo ETL.....	23
Figura 2 – Dataset	32
Figura 3 – Dataset I	32
Figura 4 – Código da Região de Saúde	34
Figura 5 – Painel Geral Coronavírus Brasil.....	35
Figura 6 – Extração da base de dados	36
Figura 7 – Importação das bibliotecas em Python	37
Figura 8 – Leitura do dataset.....	37
Figura 9 – Limpeza da base.....	37
Figura 10 – Transformação da base	38
Figura 11 – Transformação da base I.....	38
Figura 12 – Transformação da base II	38
Figura 13 – Transformação da base III	39
Figura 14 – Criação da base final.....	39
Figura 15 – Exportação da base de dados com Python	40
Figura 16 – 'dataframe_agrup_unico' salvo no diretório 'C:\TCC\export'	40
Figura 17 – Dashboard – aba Overview.....	41
Figura 18 – Aba Overview – Tabela Síntese de casos, óbitos, incidência e mortalidade.....	44
Figura 19 – Dashboard – aba Casos Novos e Acumulados.....	45
Figura 20 – Dashboard – aba Óbitos Novos e Acumulados	45
Figura 21 – Dashboard – Casos novos e acumulado de São Paulo	46

LISTA DE TABELAS

Tabela 1 – De-para do Dataset.....	33
------------------------------------	----

SUMÁRIO

1.	INTRODUÇÃO	12
2.	FUNDAMENTAÇÃO TEÓRICA	14
2.1.	O QUE FOI A COVID-19	14
2.2.	O INÍCIO E O IMPACTO DA COVID-19 NO BRASIL	17
2.3.	O PAPEL DOS DADOS NA VALIDAÇÃO DE INFORMAÇÕES	17
2.4.	O PAPEL DA GESTÃO DE DADOS NA RESPOSTA GOVERNAMENTAL	18
2.5.	QUALIDADE DOS DADOS E A DESCENTRALIZAÇÃO DE INFORMAÇÕES NO BRASIL	19
2.6.	SOBRE O DATASUS	20
2.7.	ETL	22
2.7.1.	EXTRAÇÃO DOS DADOS	23
2.7.2.	TRANSFORMAÇÃO DOS DADOS	24
2.7.3.	CARREGAMENTO DOS DADOS	24
2.8.	KDD – DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS	25
2.8.1.	INTEGRAÇÃO ENTRE O ETL E O KDD	26
2.8.2.	EXTRAÇÃO E SELEÇÃO DE DADOS	26
2.8.3.	TRANSFORMAÇÃO E PRÉ-PROCESSAMENTO	27
2.8.4.	CARREGAMENTO E MINERAÇÃO DE DADOS	27
2.8.5.	INTERPRETAÇÃO E AVALIAÇÃO	27
3.	MATERIAIS E MÉTODOS	28
3.1.	PESQUISA BIBLIOGRÁFICA	28
3.2.	PESQUISA EXPLORATÓRIA	29
3.3.	ANÁLISE DE DADOS COMO FERRAMENTA CONTRA FAKE NEWS	29
3.4.	FERRAMENTAS UTILIZADAS	30
4.	RESULTADOS E DISCUSSÕES	32
4.1.	FONTE DE DADOS	32

4.2.	EXTRAÇÃO DAS BASES	35
4.3.	TRATAMENTO DAS BASES.....	36
4.4.	CARREGAMENTO DAS BASES	39
4.5.	CRIAÇÃO DOS VISUAIS.....	40
4.6.	VISUALIZAÇÃO DE DADOS COMO APOIO À VALIDAÇÃO DA INFORMAÇÃO	46
5.	CONSIDERAÇÕES FINAIS	48
	REFERÊNCIAS.....	49

1. INTRODUÇÃO

A pandemia da COVID-19, anunciada pela Organização Mundial da Saúde (OMS) em março de 2020, representou um grande desafio sanitário, afetando milhões de vidas e desafiando sistemas de saúde ao redor do mundo. Segundo a Organização Pan-Americana da Saúde, a OMS caracterizou a COVID-19 como uma pandemia devido à rápida disseminação do vírus e ao crescente número de casos e óbitos em diversos países" (Opas, 2020, p. 1). No Brasil, o cenário não foi diferente, pois o avanço do combate à COVID-19 exigiu respostas rápidas e eficazes, baseadas em dados confiáveis, capazes de orientar ações de saúde pública e apoiar a tomada de decisão em um contexto de incertezas.

No entanto, ao mesmo tempo que a busca por informações crescia, a desinformação também se espalhava de maneira alarmante, dificultando ainda mais a distinção entre fatos e especulações. Galhardi et al. (2022) destacam que "as fakes news sobre pandemia, vacinas e saúde pública encontram terreno fértil para se proliferarem no Brasil, diante de uma população hiperconectada cuja maioria não sabe reconhecer as diferenças lógicas entre notícias falsas ou verdadeiras" (Galhardi et al., 2022, p. 1850).

Diante desse cenário de crescente desinformação, a pandemia não apenas revelou fragilidades nos sistemas de saúde, mas também expôs a vulnerabilidade da população à propagação de notícias falsas ou Fake News. Informações falsas sobre tratamentos ineficazes, teorias conspiratórias e boatos sobre vacinas se espalharam rapidamente, prejudicando a adoção de medidas preventivas e impactando diretamente a vida de milhões de pessoas. Segundo Allcott e Gentzkow (2017), "o impacto das fake news é amplificado pela velocidade com que se espalham em plataformas digitais, muitas vezes superando o alcance de informações verificadas". Um estudo da Fundação Oswaldo Cruz (Fiocruz, 2020) revelou que, entre março e abril de 2020, no Brasil, cerca de 73,7% das informações falsas sobre a COVID-19 circularam pelo WhatsApp, evidenciando o papel das redes sociais na disseminação da desinformação.

Nesse contexto, a Extração, Transformação e Carregamento de Dados (ETL) emergiu como um processo fundamental para organizar e disponibilizar informações precisas

sobre a COVID-19. Conforme destacado pela Organização Pan-Americana da Saúde (Opas, 2020), "durante uma pandemia, mais que em nenhuma outra situação de saúde pública, os sistemas de informação cumprem um papel crucial no gerenciamento dos dados e das informações necessárias com a rapidez exigida pela situação" (Opas, 2020, p. 1). A aplicação de processos de ETL permitiu integrar dados provenientes de fontes confiáveis, tornando as análises mais precisas e auxiliando na tomada de decisões baseadas em evidências.

Tendo em vista o cenário geral, a análise de dados se tornou uma ferramenta indispensável para combater a desinformação e garantir que a população tivesse acesso a informações verificadas e de fácil compreensão. A estruturação de bases de dados confiáveis possibilitou a criação de gráficos e indicadores claros, permitindo que tanto especialistas quanto a sociedade pudessem interpretar corretamente a evolução da pandemia. Além disso, a utilização de dados organizados ajuda fortalecer a credibilidade de fontes oficiais, promovendo um ambiente informacional mais seguro.

Diante desse cenário, este trabalho busca compreender o papel da análise de dados na pandemia de COVID-19 no Brasil, explorando como os processos de ETL podem tornar as informações mais acessíveis e confiáveis. Além disso, investiga-se como a estruturação desses dados pode atuar como uma ferramenta eficaz no combate à disseminação de fake news, fortalecendo o direito à informação e contribuindo para um debate público mais qualificado. Nas próximas seções, serão discutidos os métodos utilizados para a extração e organização dos dados, bem como a importância da transparência e da acessibilidade na comunicação científica e sanitária.

2. FUNDAMENTAÇÃO TEÓRICA

Este capítulo fornece a base para o desenvolvimento do projeto, apresentando os principais tópicos relacionados a este Trabalho de Conclusão de Curso (TCC).

2.1. O QUE FOI A COVID-19

Covid-19 ou SARS-CoV-2, é uma variação de um coronavírus preexistente, inicialmente, o primeiro estudo que relatou a respeito das manifestações do vírus, até então pouco conhecido, foi em janeiro de 2020. A doença é conhecida por ser uma zoonose, ou seja, uma infecção transmitida entre animais vertebrados e seres humanos, onde os animais infectados carregam e eliminam os agentes etiológicos a outros seres vivos (Souza et al. 2021). O vírus SARS-CoV-2 é um recente membro do grupo dos CoVs, um grande grupo de vírus de RNA altamente diverso. Algumas pesquisas relatam que a doença pode ter sido originada a partir dos morcegos, uma vez que a sua base sequencial genética se assemelha com a de outros CoVs (He et al. 2020).

Em princípio, especulava-se que o novo vírus se originou em um mercado de frutos do mar em Wuhan, província de Hubei, na China, e que se disseminou rapidamente a partir deste local, tornando-o epicentro da epidemia. Além disso, sabe-se que os morcegos representam o principal reservatório natural para uma diversa gama de CoV, como o SARS-CoV, o SARS-CoV-2 e o MERS-CoV14. No entanto, como este animal não é comercializado no local, então logo foi descartado a hipótese de que o vírus teria surgido neste local. Em suma, a alta semelhança entre esses dois vírus (a proteína S do SARS-CoV-2 oriunda dos morcegos e CoV oriunda do pangolim SRR10168377, um mamífero da espécie *Manis Javanica*) sugere que o animal pode ter sido um hospedeiro intermediário na transmissão do vírus para humanos. Isso significa que o vírus pode ter passado do morcego para o pangolim antes de chegar ao ser humano (morcego → pangolim → homem) (Brito et al. 2020).

Em decorrência disso, o primeiro caso da doença, até aquele momento desconhecida, ocorreu em 8 de dezembro de 2019, no entanto, só foi em 30 de dezembro de 2019,

que a CNHC (Chinese National Health Commission, que em tradução livre: Comissão Nacional de Saúde Chinesa) suspeitou de um surto de pneumonia de origem desconhecida, iniciada em Wuhan, após alguns pacientes irem às unidades de saúde e relatarem problemas respiratórios (Malik et al. 2020). Em consequência, após a doença se espalhar por diversos países asiáticos, e constatarem os mesmos sintomas, em 31 de dezembro de 2019, a Organização Mundial da Saúde (OMS) foi informada dos casos de pneumonia de etiologia desconhecida detectada na cidade de Wuhan, província de Hubei, na China, aonde, posteriormente, foi dada como uma doença infecciosa causada pela COVID-19. E foi então que, no dia 11 de fevereiro de 2020, a OMS estabeleceu a nomenclatura oficial, quando o vírus foi denominado coronavírus-2 da síndrome respiratória aguda grave (SARS-CoV-2) e a doença infecciosa do coronavírus-19 (COVID-19) (Souza et al. 2021).

Por se tratar de uma infecção respiratória aguda, a doença dissemina-se por meio de gotículas, secreções respiratórias e por meio do contato direto com o paciente infectado. O que traz luz à alta capacidade do vírus ser transmitido de 1 para 1 (transmissão direta) – tornando o contato entre membros familiares altamente suscetível à contaminação – onde o contato é mais próximo e por tempo prolongado. Além disso, embora a transmissão direta seja um dos principais meios de contaminação, é importante também ressaltar que a transmissão indireta – por meio de superfícies contaminadas –, também colaboram para a perpetuação do vírus. Por exemplo, superfícies de plástico ou aço inoxidável, permitem que o vírus permaneça viável e infeccioso por até 72h, se comparado com superfícies de cobre ou papelão (Brito et al. 2020).

Não obstante, todas as faixas etárias mostram suscetibilidade ao vírus, do recém-nascido ao idoso, no entanto, a idade média com maior vulnerabilidade ao vírus é de 55,5 anos, enquanto que a idade com maior taxa de letalidade encontra-se com 75 anos. Além disso, é importante observar outros perfis suscetíveis à doença, como é o caso de pacientes com comorbidades e homens, uma vez que este último perfil, possui maiores chances de realizar trabalhos ao ar-livre e ter questões com o tabagismo (Malik et al. 2020).

Outrossim, segundo Singhal (2020), os sintomas clínicos têm se mostrado bastante diversos, variando de paciente para paciente, como por exemplo: do estado assintomático, passando pelo desconforto na respiração à disfunção de múltiplos

órgãos. Ainda mais, há também sintomas comuns, por exemplo: febre, dor de cabeça, fadiga, dor de cabeça, mialgia e falta de ar e conjuntivite. Ao observar um subconjunto de pacientes, ao final do período de uma semana, a doença teria progredido para uma pneumonia, insuficiência respiratória ou até à morte. Ademais, a duração média da internação hospitalar em pacientes que se recuperaram de casos extremos foi de 10 dias. Os casos adversos e morte são mais comuns em idosos e naqueles com comorbidades subjacentes (50-75% dos casos fatais). Por fim, é interessante ressaltar que pacientes fora da província de Hubei tiveram sintomas mais brandos quando comparados aos moradores locais infectados. Assim como também, a gravidade e a taxa de mortalidade foram dadas como mais brandas aos pacientes fora da China. Um dos motivos que justifique a peculiaridade nos casos chineses, deve-se ao viés de seleção, uma vez que os casos relatados de Wuhan foram somente os mais graves, ou então, a uma predisposição da população local ao vírus.

E por meio de toda essa facilidade, o vírus tomou o mundo, que em decorrência da nova situação emergencial, em 21 de maio de 2020, 4.893.186 casos foram relatados, sendo 323.256 mortes, das quais 1.501.876 de casos confirmados e 90.203 mortes somente nos EUA, seguidos pelo Brasil com (271.628; 17.971), Reino Unido (248.297; 35.704), Espanha (232.555; 27.888), Itália (227.364; 32.330), França (141.312; 28.081) e China (84.507; 4645) (Malik et al. 2020). Por fim, devido à alta capacidade de transmissão do vírus, e ao aumento desenfreado de casos e óbitos, a OMS, em 30 de janeiro de 2020, declarou a situação como uma emergência de saúde pública internacional, e no dia 11 de março do mesmo ano, foi decretado estado de pandemia (Souza et al. 2021). Apesar disso, de acordo com Hassan (2020), a OMS tomou medidas preventivas a fim de diminuir a propagação da doença e a incidência de mortes pelo globo, por meio do isolamento de pacientes graves, quarentena para a população, restrição nos serviços comuns, maior vigilância sanitária, maior uso de itens de proteção (máscaras, álcool em gel, luvas etc.), desaconselhamento do contato com pessoas idosas, recém-nascidos e com comorbidades, e por fim, maior higienização nos itens de consumo diário (alimentos, maçanetas, utensílios de cozinha etc.) e no corpo (rosto, mãos, olhos, etc.). Além do mais, restrições e proteções específicas para profissionais da área da saúde também foram implementadas, como o uso obrigatório de máscaras (FFP3, N95), aventais, proteção ocular, luvas etc.

2.2. O INÍCIO E O IMPACTO DA COVID-19 NO BRASIL

Esta seção busca elucidar o impacto da pandemia da COVID-19 no Brasil, com ênfase na propagação de fake news e nos efeitos colaterais provocados por essas informações falsas. Será analisada a influência da desinformação no agravamento da crise sanitária e suas consequências sociais.

2.3. O PAPEL DOS DADOS NA VALIDAÇÃO DE INFORMAÇÕES

A pandemia não apenas intensificou a busca por informação, mas também expôs desafios no combate à propagação de conteúdos não verificados, reforçando a importância de fontes confiáveis e de mecanismos eficazes de validação. Como destaca Casero-Ripollés (2020) a pandemia de COVID-19 desencadeou um aumento significativo no consumo de notícias, impulsionado pela necessidade da população de se informar e compreender a crise sanitária. Esse crescimento foi observado tanto na mídia tradicional quanto nas plataformas digitais e páginas da web. No entanto, essa explosão informativa veio acompanhada de um fenômeno preocupante: a disseminação de boatos e desinformação, tornando mais difícil distinguir fatos de especulações.

A disseminação de fake news durante a pandemia representou um desafio significativo para a população brasileira, impactando diretamente a forma de consumir e interpretar informações. Segundo Wardle e Derakhshan (2017), as notícias falsas são caracterizadas por sua intenção de enganar e manipular, explorando emoções e crenças pré-existentes para se disseminarem rapidamente nos principais veículos de comunicação. No contexto da crise sanitária, essa propagação descontrolada dificultou a implementação de políticas públicas, atrasando campanhas de vacinação e promovendo desconfiança em relação às recomendações de especialistas (Lorenzetti; Vicentini, 2021).

Além de prejudicar a adoção de medidas preventivas, a circulação de desinformação contribuiu para a instalação de um medo generalizado, alimentado por narrativas distorcidas. Segundo Allcott e Gentzkow (2017), o impacto das fake news é

amplificado pela velocidade com que se espalham em plataformas digitais, muitas vezes superando o alcance de informações verificadas. No Brasil, estudos apontam que a desinformação esteve diretamente associada a crises institucionais e à polarização social, dificultando o combate à pandemia e gerando riscos à saúde pública (Recuero; Soares; Gruzd, 2020).

Uma pesquisa da Fundação Oswaldo Cruz revelou que, entre março e abril de 2020, 73,7% das notícias falsas relacionadas à COVID-19 circularam pelo WhatsApp, enquanto cerca de 30% foram disseminadas pelo Facebook e Instagram (Fiocruz, 2020). Além desta pesquisa, outro estudo realizado pelo Instituto Reuters para Estudos do Jornalismo, da Universidade de Oxford, apontou que 40% das pessoas entrevistadas no Brasil tiveram acesso à desinformação sobre a COVID-19 por meio do WhatsApp. O mesmo estudo destacou que 41% dos brasileiros utilizavam este aplicativo para se atualizar sobre a pandemia (Newman et al., 2020).

2.4. O PAPEL DA GESTÃO DE DADOS NA RESPOSTA GOVERNAMENTAL

A resposta governamental à pandemia no Brasil foi marcada por controvérsias e críticas. A adoção de medidas como o uso da cloroquina, mesmo sem comprovação científica, gerou muitos debates. Em maio de 2020, o Ministério da Saúde autorizou o uso da cloroquina para casos leves de COVID-19, enfatizando que a decisão caberia ao médico e ao paciente, apesar da ausência de evidências conclusivas sobre sua eficácia (Ministério da Saúde, 2020). Esse episódio reforçou a necessidade de embasamento técnico e científico para a formulação de políticas de saúde e tomada de decisões, evidenciando o impacto da desinformação até mesmo no âmbito governamental. Segundo Puri et al. (2020), a disseminação de informações não verificadas pode minar a confiança pública nas autoridades de saúde e comprometer a eficácia das intervenções durante crises sanitárias.

A pandemia demonstrou que a forma como os dados são coletados, organizados e analisados influencia diretamente a tomada de decisões e a percepção pública sobre a crise sanitária. A falta de clareza e a divergência entre fontes oficiais dificultaram a implementação de estratégias eficazes, aumentando a incerteza e a polarização social. Conforme apontam Chen et al. (2020), a transparência e a consistência na

comunicação de dados são fundamentais para manter a confiança pública e promover a adesão às medidas de saúde pública.

Nesse sentido, a pandemia evidenciou, de forma ainda mais enfática, a necessidade da gestão eficaz dos dados como um elemento estratégico para o enfrentamento de situações de emergência em saúde pública. A organização e a interpretação correta das informações são fundamentais para a formulação de políticas públicas baseadas em evidências, permitindo respostas rápidas e coordenadas (Organização Pan-Americana da Saúde, 2023). Além disso, a transparência e a disponibilidade de dados confiáveis aumentam a confiança pública e facilitam a colaboração entre diferentes setores da sociedade (Silva; Santos; Oliveira, 2022).

Frente a isso, pode-se perceber que a pandemia evidenciou a importância de dados estruturados e acessíveis para enfrentar desafios sanitários globais, tornando-se essencial discutir como a análise de dados pode ser utilizada como uma ferramenta eficaz contra a disseminação de fake news. A organização e a interpretação correta dos dados são fundamentais para diferenciar informações verificadas de conteúdos duvidosos ou manipulados. Como destaca Dong et al. (2020), o acesso a dados confiáveis e bem estruturados permitiu o desenvolvimento de painéis informativos e sistemas de monitoramento, que auxiliaram na transparência e no combate à desinformação durante a pandemia de COVID-19. Além disso, Zarocostas (2020) reforça que a luta contra a desinformação se tornou uma das principais frentes no enfrentamento da crise sanitária, sendo essencial o investimento em sistemas de dados confiáveis e comunicação clara com a sociedade.

2.5. QUALIDADE DOS DADOS E A DESCENTRALIZAÇÃO DE INFORMAÇÕES NO BRASIL

Em tempos de crise sanitária, a qualidade e integridade dos dados são fundamentais, um fator decisivo na gestão da saúde pública. Durante a pandemia de COVID-19, a necessidade de informações confiáveis nunca foi tão evidente, decisões precisavam ser tomadas rapidamente e embasadas em evidências concretas, tornou-se essencial garantir que as informações disponíveis refletissem a realidade com o máximo de precisão. No Brasil, desafios como a subnotificação de casos, a descentralização dos

registros e a falta de padronização nos critérios de diagnóstico dificultaram a avaliação precisa da evolução da doença. Deste modo pode-se destacar como inconsistências ou falhas nos processos de coleta e tratamento de dados, puderam levar a interpretações equivocadas e, conseqüentemente, a políticas ineficazes e muitas vezes até perigosas. Siqueira et al. (2022) destacam que a aplicação de metodologias rigorosas na validação dos dados foi fundamental para aprimorar a vigilância epidemiológica, possibilitando decisões mais bem fundamentadas e transparentes.

A descentralização dos sistemas de notificação de casos e óbitos representou um dos maiores desafios durante a pandemia de COVID-19 no Brasil. Embora o Ministério da Saúde fosse responsável pela consolidação dos dados em nível nacional, estados e municípios adotaram protocolos distintos, gerando discrepâncias na comunicação e dificultando análises comparativas entre diferentes regiões. Orellana (2020) apontam que a ausência de um sistema unificado de vigilância epidemiológica comprometeu a capacidade de resposta à pandemia, tornando evidente as desigualdades regionais na notificação de casos e óbitos. Além disso, a subnotificação de casos, agravada pela escassez de testes e por atrasos na atualização dos registros, contribuiu para distorções entre os números oficiais e a realidade vivida pelas populações mais vulneráveis.

2.6. SOBRE O DATASUS

O DATASUS (Departamento de Informática do Sistema Único de Saúde) é uma divisão do Ministério da Saúde do Brasil responsável pela gestão da informação em saúde no país. Seu portal pode ser acessado pelo endereço: <<https://datasus.saude.gov.br/>>.

Criado para coletar, armazenar, processar e disseminar dados referentes à saúde pública, o DATASUS desempenha papel fundamental no suporte à formulação de políticas públicas, no acompanhamento de indicadores epidemiológicos e na promoção da transparência e do acesso à informação para a sociedade. Desde sua criação, em 1991, o DATASUS vem se consolidando como pilar essencial da gestão em saúde, fornecendo suporte tecnológico e metodológico para o funcionamento do SUS (Lima et al., 2015; Brasil, 2020).

O DATASUS desempenha um papel altamente estratégico na consolidação das informações em saúde no Brasil. Entre suas principais atribuições, o DATASUS disponibiliza sistemas de informação que abrangem áreas como morbidade, mortalidade, procedimentos ambulatoriais e hospitalares, vacinação e vigilância em saúde. Conforme destacado por Lima et al. (2015) O DATASUS, é responsável por implementar sistemas de informação e suporte tecnológico ao SUS, constituindo-se em ferramenta essencial para a análise situacional em saúde e tomada de decisão. Esses sistemas são alimentados por hospitais, unidades de saúde e secretarias municipais e estaduais, consolidando uma vasta base de dados que permite análises detalhadas sobre o estado de saúde da população brasileira. O Sistema de Informações Hospitalares (SIH-SUS), por exemplo, cobre entre 60% e 70% de todas as internações hospitalares realizadas no Brasil, porém ainda apresenta limitações como subnotificação e registros inconsistentes, por este e outros fatores, sua análise exige cautela, assim como o uso de suas informações. Bastos et al. (2023).

Durante a pandemia de COVID-19, o DATASUS teve importância ainda mais destacada. Ele foi a principal fonte oficial de dados relacionados a casos confirmados, internações, vacinação e óbitos, entre outros indicadores críticos para o acompanhamento da evolução da doença no Brasil. Através do Painel Coronavírus, plataforma criada para centralizar e divulgar informações atualizadas sobre a pandemia, o governo federal disponibilizou dados públicos que permitiram o monitoramento da situação em tempo real. Segundo Schrarstzhaupt et. al. (2024)

Neste trabalho, os dados utilizados para o estudo de caso sobre a COVID-19 no Brasil entre 2020 e 2025 foram extraídos diretamente do Painel Coronavírus, disponibilizado pelo DATASUS. Conforme destaca Castelo et al. (2021) O Painel Coronavírus do Ministério da Saúde foi estruturado com base em dados do DATASUS, permitindo o acompanhamento em tempo real da evolução dos casos, internações, óbitos e vacinação em todo o território nacional. A escolha dessa base de dados se justifica pela credibilidade da fonte, pela amplitude e riqueza das informações oferecidas, pelo fácil acesso às bases públicas e pela confiabilidade dos dados disponibilizados, fatores essenciais para análises robustas no contexto da pandemia. Conforme destacado por Birck et al., (2023, p. 2) A base de dados do DATASUS é adequada para estudos epidemiológicos e farmacológicos, possibilitando análises robustas em larga escala.

O uso dos dados do DATASUS também reforça a importância de práticas corretas de Extração, Transformação e Carregamento de Dados (ETL) em projetos de análise de dados. Dada a grande quantidade e a diversidade de informações disponibilizadas, foi necessário aplicar processos de tratamento, padronização e integração dos dados para que as análises realizadas fossem precisas, confiáveis e úteis para o objetivo do estudo. Além disso, a plataforma representou um avanço em termos de transparência e governança dos dados de saúde, ao permitir análises em tempo real e subsidiar tanto a gestão pública quanto a produção científica (Ribeiro; Bernardes; Moreira, 2021).

Assim, compreender o que é o DATASUS e sua relevância para a coleta e disseminação de informações em saúde no Brasil é essencial para contextualizar a origem e a qualidade dos dados utilizados no desenvolvimento deste trabalho.


2.7. ETL

Ao se deparar com o objetivo de analisar um conjunto de dados, a fim de gerar insights e então trazer à luz soluções para um problema em questão, é necessário deixar-se claro que, para que tal tarefa seja feita de maneira clara, uniforme e coesa, e quando o material de estudos são os dados, a maior ferramenta será o processo ETL. De acordo com Kimball e Caserta (2011), o ETL constitui a espinha dorsal de qualquer projeto de Data Warehouse, pois é nesse processo que os dados são organizados e preparados para análises consistentes. A ausência de um fluxo estruturado compromete a confiabilidade das análises e a tomada de decisão baseada em dados.

O processo ETL (extração, transformação e carregamento) deriva da junção de três etapas importantes que visam chegar na análise de dados. Cada etapa, exemplifica de forma clara, o processo de tratamento que um dado precisa passar para estar pronto para ser analisado. Além disso, cada etapa procura respeitar os recursos disponíveis ao seu usuário, e, as regras de negócios que terão impacto no produto final. Inmon (2005) reforça que o ETL não deve ser compreendido apenas como uma sequência técnica, mas como um processo estratégico que garante a consistência, a qualidade e a integração entre diferentes fontes de dados, permitindo análises históricas e comparativas ao longo do tempo.

Em suma, o processo ETL oferece uma análise de dados precisa, atendendo aos padrões regulatórios, como a Lei Geral de Proteção de Dados (LGPD), e conforme Cardoso et al. (2021), a etapa de transformação no ETL deve incorporar práticas de anonimização e pseudonimização de dados sensíveis, em conformidade com a LGPD, de modo a garantir segurança e reduzir riscos de exposição de informações pessoais e de conformidade, além de facilitar processos de automatização. Segundo o site da AWS Amazon, "O processo de ETL funciona em três etapas: (1) Extração dos dados relevantes do banco de dados de origem; (2) Transformação dos dados para que sejam mais adequados a análises; (3) Carregamento dos dados no banco de dados de destino" (AWS Amazon, 2024), sendo representado por meio da Figura 1.

Figura 1 – Processo ETL



Fonte: Souza

2.7.1. EXTRAÇÃO DOS DADOS

A extração dos dados funciona da seguinte forma: dados brutos de diversas fontes, ou apenas de uma única fonte, são retirados de seu ponto de origem e levados ao seu destino, seja de forma automatizada ou manual, podendo ser uma extração gradual ou completa. Segundo Golfarelli e Rizzi (2009), a etapa de extração deve considerar não apenas a coleta dos dados, mas também a identificação de suas limitações, como

a qualidade da fonte original, a periodicidade de atualização e possíveis inconsistências que possam comprometer a análise futura.

O ponto de destino servirá como um meio de armazenamento, podendo ser temporário ou fixo, onde será alocada as bases de dados, que serão consumidas pelo usuário para a realização da próxima etapa do processo.

2.7.2. TRANSFORMAÇÃO DOS DADOS

A transformação dos dados busca melhorar a qualidade dos dados, desde remover erros, duplicidade (a depender da regra de negócio) a deletar campos desnecessários ou simplificar os dados.

Esta fase é necessária para manter os dados em ordem, ou padronizados, garantindo que haja uma melhor conversa entre o mundo do usuário e a regra de negócio, uma vez que todo o conjunto de dados precisa estar de acordo com a regra de negócio. E ao garantir isso, permitirá que o usuário encontre soluções rapidamente para suas questões. Kimball (2011) destaca que essa etapa é a mais complexa do processo ETL, pois é nela que se realizam operações como agregações, cálculos derivados, padronização de formatos e a integração de dados oriundos de sistemas heterogêneos. Uma transformação bem projetada reduz redundâncias e assegura consistência semântica entre diferentes bases.

2.7.3. CARREGAMENTO DOS DADOS

Já no carregamento dos dados, todos os dados saem desse ‘ambiente de tratamento’ e são transportados para este novo ‘ambiente de consumo’.

Tal carregamento pode ser feito de forma parcial ou completa, mas o crucial, é estar de fácil acesso ao usuário, seja este um usuário que utilizará o dado como ‘ferramenta de consumo’ (como analistas em geral) ou como ‘ferramenta de trabalho’ (como engenheiros, analistas ou cientistas de dados).

Desta forma, a etapa de carregamento garante que os dados tratados sejam inseridos em sistemas de destino, como bancos de dados analíticos ou Data Warehouses. É nesse momento que os dados se tornam disponíveis para ferramentas de Business Intelligence (BI) e Data Analytics. Segundo Singh e Singh (2016) apontam que a eficiência do carregamento é determinante para a performance das consultas analíticas, sendo recomendada a aplicação de técnicas de particionamento e indexação para otimizar o acesso futuro às informações.

2.8. KDD – DESCOBERTA DE CONHECIMENTO EM BASES DE DADOS

Dando continuidade ao processo de tratamento e análise de dados abordado no capítulo anterior, é importante compreender o papel do KDD (Knowledge Discovery in Databases) ou Descoberta de Conhecimento em Bases de Dados como um complemento conceitual ao processo ETL. Enquanto o ETL atua de forma mais operacional, garantindo que os dados estejam estruturados e prontos para uso, o KDD representa o ciclo analítico que transforma esses dados tratados em conhecimento interpretável e aplicável.

De acordo com Fayyad, Piatetsky-Shapiro e Smyth (1996), o KDD é composto por cinco etapas principais: seleção dos dados, pré-processamento e limpeza, transformação, mineração de dados e interpretação/avaliação dos resultados. Essas fases são interdependentes e formam um fluxo contínuo que vai desde a coleta até a obtenção de insights úteis.

Conforme Freitas (2000), o conhecimento descoberto precisa apresentar três características essenciais: deve ser correto, compreensível e útil. Além disso, o método de descoberta deve ser eficiente, genérico e flexível, para se adaptar a diferentes tipos e volumes de dados. Essa visão reforça a ideia de que o valor real dos dados não está apenas em sua coleta, mas na capacidade de transformá-los em informação significativa.

O KDD e o ETL compartilham, portanto, um mesmo propósito: garantir que o dado percorra um caminho lógico, passando da sua forma bruta até se tornar um recurso confiável de análise e apoio à decisão. O ETL fornece a base limpa e consistente,

enquanto o KDD conduz a exploração analítica e a interpretação dos resultados, fechando o ciclo de descoberta do conhecimento.

2.8.1. INTEGRAÇÃO ENTRE O ETL E O KDD

No contexto deste trabalho, a integração entre ETL e KDD se mostra essencial para compreender como os dados da COVID-19, oriundos do DATASUS e do Painel Coronavírus, podem ser tratados, analisados e convertidos em informações úteis à sociedade e à gestão pública.

Enquanto o ETL garante a organização, limpeza e padronização dos dados, o KDD amplia essa estrutura, aplicando métodos de descoberta de padrões e correlações que permitem compreender o comportamento da pandemia no Brasil. Essa combinação não apenas potencializa o valor analítico dos dados, mas também favorece a criação de indicadores confiáveis que auxiliam o combate à desinformação.

Segundo Steiner et al. (2006), a etapa de pré-processamento e limpeza é determinante para a qualidade dos resultados da mineração, pois erros e lacunas na base de dados podem comprometer toda a descoberta de conhecimento. Assim, o ETL se consolida como o alicerce técnico dentro do processo KDD.

2.8.2. EXTRAÇÃO E SELEÇÃO DE DADOS

A etapa de extração, descrita anteriormente no processo ETL, corresponde à fase de seleção dos dados no KDD. É nesse ponto que se definem as fontes relevantes e os atributos a serem analisados. De acordo com Heisler e Assunção (2024), essa escolha influencia diretamente a qualidade do conhecimento a ser descoberto. No presente estudo, os dados foram extraídos de fontes oficiais como o DATASUS e o Painel Coronavírus, abrangendo variáveis como casos confirmados, internações, óbitos e vacinação entre 2020 e 2025.

2.8.3. TRANSFORMAÇÃO E PRÉ-PROCESSAMENTO

A fase de transformação no ETL está alinhada ao pré-processamento e limpeza de dados do KDD. Aqui, os dados passam por correção de erros, remoção de duplicidades e padronização de formatos, garantindo coerência entre diferentes bases. Segundo Steiner et al. (2006), essa etapa define a confiabilidade dos resultados obtidos posteriormente na mineração. No caso da COVID-19, esse tratamento envolveu harmonizar informações entre diferentes sistemas de notificação e uniformizar campos epidemiológicos como sintomas, datas e evolução clínica.

2.8.4. CARREGAMENTO E MINERAÇÃO DE DADOS

O carregamento, última etapa do ETL, se conecta à transformação e mineração de dados do KDD. É nesse momento que os dados tratados são armazenados em um repositório analítico, permitindo a aplicação de técnicas estatísticas e algoritmos de mineração para identificar padrões e relações. Heisler e Assunção (2024), em seu estudo sobre o uso de KDD em dados da COVID-19, observaram que o uso de árvores de decisão revelou associações significativas entre sintomas e desfechos clínicos, demonstrando como a mineração transforma dados organizados em conhecimento acionável.

2.8.5. INTERPRETAÇÃO E AVALIAÇÃO

Por fim, a etapa de interpretação e avaliação do KDD é representada neste trabalho pelas análises e dashboards construídos em Power BI. Essa fase tem como objetivo traduzir os resultados analíticos em informações claras, acessíveis e de valor prático. Conforme Steiner et al. (2006), interpretar resultados é o ponto em que o conhecimento técnico se converte em suporte real à decisão. Os painéis visuais elaborados neste estudo permitem acompanhar a evolução da COVID-19 por região, identificar tendências e apresentar indicadores de forma objetiva, apoiando a compreensão pública e institucional dos dados.

3. MATERIAIS E MÉTODOS

Esta seção busca apresentar a metodologia adotada na pesquisa, destacando as estratégias utilizadas para garantir a consistência teórica e a confiabilidade das análises realizadas. Serão descritos os tipos de pesquisa empregados, com ênfase na pesquisa bibliográfica, e na pesquisa exploratória. O objetivo é evidenciar como a combinação dessas abordagens fornece suporte adequado para o estudo, assegurando rigor científico e alinhamento entre teoria e prática.

3.1. PESQUISA BIBLIOGRÁFICA

A pesquisa bibliográfica, foi utilizada neste trabalho como base para a construção teórica, permitindo a fundamentação dos conceitos diretamente relacionados ao processo ETL (Extração, Transformação e Carregamento de Dados), bem como das discussões acerca da propagação de desinformação e do papel da análise de dados durante o período da pandemia de COVID-19. De acordo com Gil (2008, p.44), “a pesquisa bibliográfica é desenvolvida a partir de material já elaborado, constituído principalmente de livros e artigos científicos”.

Neste sentido, a revisão bibliográfica propriamente dita, foi realizada com base em artigos de fontes como SciELO e PubMed, e em documentos oficiais disponibilizados por organizações nacionais e internacionais como Ministério da Saúde, Fiocruz, OMS e OPAS. Essa análise permitiu a utilização de forma sistêmica do conhecimento existente sobre ETL e análise de dados, ao mesmo tempo em que forneceu embasamento para compreender como as informações estruturadas podem auxiliar no enfrentamento das fake news.

Segundo Marconi e Lakatos (2017), a pesquisa bibliográfica é indispensável quando se busca compreender o estado atual de determinado tema, identificar lacunas e direcionar a análise para aspectos mais relevantes. Assim, este trabalho se apoia em uma ampla base de autores que discutem desde metodologias de tratamento de dados (Kimball; Caserta, 2011; Inmon, 2005) até a necessidade de transparência na

divulgação de informações em saúde (Souza et al., 2021; Ribeiro; Bernardes; Moreira, 2021).

3.2. PESQUISA EXPLORATÓRIA

Além da fundamentação teórica, este trabalho adota também uma abordagem exploratória. Segundo Vergara (2009, p. 47), a pesquisa exploratória é realizada em áreas nas quais há pouco conhecimento acumulado e sistematizado, sendo adequada para proporcionar maior familiaridade com o problema.

A escolha pela pesquisa exploratória se justifica pelo fato de que, embora existam estudos sobre a pandemia de COVID-19 e o uso de dados em saúde, o recorte específico envolvendo o processo ETL aplicado ao contexto brasileiro, entre 2020 e 2024, ainda se apresenta pouco consolidado. Dessa forma, a exploração inicial dos bancos de dados públicos foi necessária para identificar variáveis relevantes (casos confirmados, óbitos, vacinação), avaliar a consistência das informações e compreender como poderiam ser estruturadas para análises posteriores. Para isto foi utilizado conforme mencionado, a base de dados do Ministério da Saúde do Brasil o DATASUS, especificamente o Painel Coronavírus, disponibilizado dentro desta base.

Conforme Marconi e Lakatos (2017), a pesquisa exploratória possibilita estabelecer hipóteses e definir direções mais precisas para investigações futuras. No presente trabalho, a etapa exploratória foi fundamental para mapear os dados disponíveis no Painel Coronavírus e no DATASUS, permitindo maior compreensão das limitações e potencialidades das bases utilizadas.

3.3. ANÁLISE DE DADOS COMO FERRAMENTA CONTRA FAKE NEWS

A pandemia de COVID-19 evidenciou a importância da análise de dados como um instrumento essencial para validar informações científicas e combater a desinformação. Em um cenário marcado pela rápida disseminação de notícias falsas, os processos de Extração, Transformação e Carregamento (ETL) permitiram a

estruturação de bases confiáveis, fundamentais para a tomada de decisões baseadas em evidências.

Este capítulo explora o papel dos dados na validação de informações, a importância de fontes confiáveis no combate às fake news e a análise de indicadores que auxiliaram na compreensão do contexto da pandemia. Tal abordagem metodológica sustenta a credibilidade do estudo e fortalece sua contribuição para um debate público qualificado.

A pluralidade de elementos analisados, como diferentes indicadores epidemiológicos e recortes temporais e geográficos, contribui para uma compreensão mais precisa e confiável da realidade, uma vez que reduz interpretações baseadas em dados isolados. Segundo Fayyad et al. (1996), a descoberta de conhecimento ocorre a partir da análise conjunta de múltiplos atributos, enquanto Turban et al. (2011) destacam que decisões baseadas em dados tornam-se mais consistentes quando apoiadas na integração de diversos indicadores. Nesse sentido, a análise estruturada e multidimensional dos dados fortalece a validação das informações e o enfrentamento da desinformação.

3.4. FERRAMENTAS UTILIZADAS

Para a execução da pesquisa, foi utilizado o ambiente Anaconda, amplamente empregado no campo da análise de dados. Trata-se de uma plataforma que integra bibliotecas e ferramentas voltadas para manipulação, visualização e análise de grandes volumes de dados, permitindo também a construção de modelos de aprendizado de máquina. Conforme documentação oficial da Anaconda (2025), sua instalação adequada é essencial para garantir o pleno funcionamento das bibliotecas necessárias ao desenvolvimento de projetos analíticos.

No contexto desta pesquisa, o Anaconda serviu como ponto de partida para a manipulação dos dados obtidos em fontes oficiais, viabilizando a aplicação dos processos ETL detalhados no capítulo seguinte.

Além do Anaconda, foi utilizada a ferramenta Microsoft Power BI, reconhecida como uma das plataformas mais consolidadas de Business Intelligence (BI). O Power BI foi

empregado na construção de dashboards interativos, permitindo a visualização dos dados tratados por meio de gráficos dinâmicos, painéis comparativos e indicadores personalizáveis. De acordo com a própria Microsoft (2023), o Power BI possibilita transformar dados em informações acessíveis e compreensíveis, apoiando a tomada de decisão em diferentes contextos organizacionais.

As informações que alimentaram os dashboards foram extraídas de bases oficiais do DATASUS e do Painel Coronavírus do Ministério da Saúde, plataformas que consolidam registros nacionais sobre casos novos e confirmados e óbitos relacionados à COVID-19. A integração entre as etapas de ETL e o Power BI garantiu a criação de painéis visuais que facilitaram a interpretação dos dados, contribuindo para análises consistentes e para a compreensão do cenário da pandemia (Souza et al., 2021; Ribeiro; Bernardes; Moreira, 2021).

Portanto, a combinação entre o ambiente de programação (Anaconda), a ferramenta de visualização (Power BI) e as bases de dados públicas (DATASUS e Painel Coronavírus) forneceu a infraestrutura necessária para realizar as análises e produzir resultados confiáveis, que serviram como suporte para a discussão dos achados apresentados nos capítulos seguintes.

4. RESULTADOS E DISCUSSÕES

Nesta seção são apresentados os resultados alcançados e as discussões que deles decorrem, com o intuito de oferecer uma visão clara e estruturada sobre o tema estudado. O percurso metodológico é descrito em etapas, iniciando pela identificação da fonte de dados, seguida da extração e do tratamento das bases, até o carregamento no ambiente de análise. Por fim, são apresentados os visuais elaborados, que servem de apoio para a interpretação e compreensão dos achados.

4.1. FONTE DE DADOS

Como mencionando anteriormente, as informações analisadas foram extraídas do Painel Coronavírus e do DATASUS, fontes oficiais consolidadas pelo Ministério da Saúde, reconhecidas por sua relevância e confiabilidade no acompanhamento epidemiológico nacional (Lima et al., 2015; Schrarstzhaupt et al., 2024; Ribeiro, Bernardes e Moreira, 2021). A base contém informações a respeito da Covid-19 no Brasil a partir do ano de 2020 até a data em que esta pesquisa foi desenvolvida. Inicialmente, pode-se ter uma prévia das colunas que constam no dataset público por meio das Figuras 2 e 3.

O dataset em questão possui o formato em .csv, com aproximadamente 44,5 MB, e com 17 colunas ao todo.

Figura 2 – Dataset

regiao	estado	municipio	coduf	codmun	codRegiaoSaude	nomeRegiaoSaude	data	semanaEpi	populacaoTCU2019	casosAcumulado
Brasil			76				25/02/2020	9	210147125	0
Brasil			76				26/02/2020	9	210147125	1
Brasil			76				27/02/2020	9	210147125	1

Fonte: Autoras

Figura 3 – Dataset I

casosAcumulado	casosNovos	obitosAcumulado	obitosNovos	Recuperadosnovos	emAcompanhamentoNovos	interior/metropolitana
0	0	0	0	0	0	0
1	1	0	0	1	0	0
1	0	0	0	1	0	0

Fonte: Autoras

Desta forma, a Tabela 1 apresenta uma relação das colunas com o tipo de dado que as compõem, seguido de um exemplo.

Tabela 1 – De-para do Dataset

Nome Coluna	Tipo Dado	Exemplo Dado
regiao	texto	Nordeste
estado	texto	CE
municipio	texto	Acopiara
coduf	texto	76
codmun	texto	110000
codRegiaoSaude	texto	11001
nomeRegiaoSaude	texto	ALTO TAPAJOS
data	data	25/02/2020
semanaEpi	texto	8
populacaoTCU2019	número inteiro	210147125
casosAcumulado	número inteiro	1536345
casosNovos	número inteiro	21
obitosAcumulado	número inteiro	28215
obitosNovos	número inteiro	141
Recuperadosnovos	número inteiro	110
emAcompanhamentoNovos	número inteiro	12
interior/metropolitana	texto	1

Fonte: Autoras

Além disso, é necessário também compreender os conceitos de cada campo:

1. Região (regiao) – Refere-se às regiões do Brasil, exemplos: Norte, Nordeste, Centro-Oeste, Sudeste, Sul;
2. Estado (estado) – diz respeito aos estados brasileiros, exemplos: Roraima, Sergipe, Mato Grosso, Espírito Santo, Santa Catarina;
3. Município (municipio) – Refere-se aos municípios brasileiros, exemplo: São Paulo, Rio de Janeiro, Fortaleza;
4. Código Unidade Federativa / Código Unidade da Federação (coduf) – remete-se aos códigos de identificação que cada estado brasileiro possui, exemplos: AC – 12; AP – 16;
5. Código dos Municípios (codmun) – remete-se aos códigos de identificação que cada cidade brasileira possui, por exemplo, no estado do Tocantins: Abreulândia – 1700251; Ponte Alta do Bom Jesus – 1717800;
6. Código da Região de Saúde (codRegiaoSaude) – refere-se aos códigos de identificação que os municípios próximos compartilham entre si. Essa divisão é determinada por meio da semelhança cultural, econômica e social, além da comunicação e da infraestrutura de transportes existente entre cidades (Ministério da Saúde, 2023).

Sabendo disso, o mesmo aplica-se para a coluna Nome da Região de Saúde (nomeRegiaoSaude) como mostra na Figura 4:

Figura 4 – Código da Região de Saúde

Regiões de Saúde CUIDA MAIS BRASIL		
UF	CÓDIGO DA REGIÃO DE SAÚDE	NOME DA REGIÃO DE SAÚDE
AC	12001	Alto Acre
AC	12002	Baixo Acre e Purus
AC	12003	Juruá e Tarauacá/Envira

Fonte: Ministério da Saúde, 2023

7. Data (data) – entende-se o campo data, o momento em que foi constado a doença no organismo do paciente;
8. Semana Epidemiológica (semanaEpi) – diz respeito a um sistema de padronização de contagem de semanas, muito utilizado na vigilância da saúde pública, a fim de facilitar o acompanhamento e a análise de dados de doenças ao longo do tempo.
9. População TCU 2019 (populacaoTCU2019) – compreende-se este campo, como a população estimada no Brasil no ano referenciado pelo TCU (Tribunal de Contas da União). Tal secretaria é especializada em fiscalizar a gestão da aplicação dos recursos públicos federais, por meio de auditorias, inspeções e no monitoramento de constas públicas (Tribunal de Contas da União, s.d);
10. Casos Acumulado (casosAcumulado)/Casos Novos (casosNovos) – os dados de casos acumulados e casos novos referem-se ao número total de casos confirmados por COVID-19 que foram registrados pelas Secretarias Municipais e Estaduais de Saúde no período considerado.
11. Óbitos Acumulado (obitosAcumulado) – compreende-se o número total de óbitos confirmados por COVID-19 que foram registrados pelas Secretarias Municipais e Estaduais de Saúde no período considerado.
12. Óbitos Novos (obitosNovos) – diz respeito ao número de óbitos novos confirmados por COVID-19 que foram registrados pelas Secretarias Municipais e Estaduais de Saúde na data em que tiveram a confirmação laboratorial ou clínico epidemiológica. Não reflete a data de ocorrência do óbito.
13. (Casos) Novos Recuperados (Recuperadosnovos) – para os casos novos recuperados, considera-se dentro desta categoria, os casos recuperados que


tiveram dois resultados negativos para SARS-CoV-2 com pelo menos 1 dia de intervalo.

14. (Casos) Novos em Acompanhamento (emAcompanhamentoNovos) – são considerados como “em acompanhamento” todos os casos notificados nos últimos 14 dias pelas Secretarias Estaduais de Saúde e que não evoluíram para óbito, como também aqueles que foram internados nos últimos 14 dias e que não apresentaram registro de alta ou óbito.
15. Interior/Metropolitana (interior/metropolitana) – tal campo entende-se como uma ‘flag’, na qual informa ao analista se o município é interiorano ou região metropolitana.

4.2. EXTRAÇÃO DAS BASES


Essa fase inicial reflete a etapa de Extração do processo ETL descrito no capítulo anterior, responsável por reunir dados brutos de fontes distintas para posterior tratamento (Kimball e Caserta, 2011; Golfarelli e Rizzi, 2009). Desta forma é extraída a massa de dados pública do DATASUS.

Figura 5 – Painel Geral Coronavírus Brasil



Fonte: Ministério da Saúde

É necessário, de antemão, extrair o arquivo baixado em um diretório destino, onde será feita a leitura da base e a transformação para uma base consolidada. O botão de extração pode ser visualizado por meio da Figura 5 no canto superior direito e a extração na Figura 6.

Figura 6 – Extração da base de dados

Fonte: Autoras

Após isso, é feito o upload das bases para um repositório, onde estas serão tratadas e transformadas em uma base consolidada e posteriormente consumida.

4.3. TRATAMENTO DAS BASES

Em primeiro lugar, é necessário iniciar o processo com o import das bibliotecas Python que serão utilizadas no ambiente Jupyter Notebook, por meio do Anaconda, como é evidenciado na Figura 7.

Foram importadas as bibliotecas ‘pandas’, que servirá para tratamento dos dados, ‘os’ que ajudará na comunicação com o sistema operacional da máquina e ‘IPython.display’, um módulo que ajudará a transformar o output em um formato de texto HTML – melhorando o entendimento da base ao longo do desenvolvimento do processo de transformação.

O tratamento da base seguiu as diretrizes metodológicas da fase de Transformação do processo ETL, descrita por Kimball (2011) e Inmon (2005), que ressaltam a importância

da padronização e da eliminação de inconsistências. Essa etapa também se relaciona ao pré-processamento do processo KDD, garantindo coerência e integridade dos dados antes da análise (Steiner et al., 2006).

Figura 7 – Importação das bibliotecas em Python

```
# Importando as bibliotecas necessárias que serão utilizadas no processo ETL da massa de dados
import pandas as pd
import os
import numpy as np
from IPython.display import display, HTML
```

Fonte: Autoras

Logo após, foram desenvolvidas linhas de código para realizar a leitura dos arquivos CSV, e em seguida, a combinação de cada arquivo em um único dataframe.

Figura 8 – Leitura do dataset

```
# Lê todos os arquivos CSV
lista_dataframes = []

for arquivo in arquivos_csv:
    caminho_completo = os.path.join(caminho_diretorio, arquivo)
    df = pd.read_csv(caminho_completo, delimiter=';', encoding='utf-8')
    lista_dataframes.append(df)

# Combina todos os arquivos em um único DataFrame
dataframe_unico = pd.concat(lista_dataframes, ignore_index=True)
```

Fonte: Autoras

Após a consolidação de todos os arquivos, tal como mostrado na Figura 8, foram feitas transformações na base de dados – normalização dos dados –, por meio de padronizações e limpezas.

Para o projeto em questão, foi necessário manter na base, somente os dados das capitais de cada estado, a fim de diminuir a granularidade na apresentação das informações, conforme verifica-se na Figura 9.

Figura 9 – Limpeza da base

```
# Manter apenas as linhas onde 'codmun' e 'interior/metropolitana' são nulas
dataframe_unico = dataframe_unico[dataframe_unico['codmun'].isna()]
dataframe_unico = dataframe_unico[dataframe_unico['interior/metropolitana'].isna()]
```

Fonte: Autoras

Para campos de texto, conforme exposto na Figura 10, é importante garantir que não haja valores 'NaN', uma vez que estes valores não podem ser identificados por meio da linguagem, caracterizando-os como sujeira, impedindo assim uma confiabilidade maior na base.

Figura 10 – Transformação da base

```
# Substituir valores NaN para 'N.A.' em colunas Object
dataframe_unico['estado'] = dataframe_unico['estado'].fillna('Brasil') # substituir por 'Brasil'
dataframe_unico['regiao'] = dataframe_unico['regiao'].fillna('N.A.') #substituir por 'N.A.'
dataframe_unico['municipio'] = dataframe_unico['municipio'].fillna('N.A.') #substituir por 'N.A.'
dataframe_unico['codmun'] = dataframe_unico['codmun'].fillna('N.A.') #substituir por 'N.A.'
dataframe_unico['codRegiaoSaude'] = dataframe_unico['codRegiaoSaude'].fillna('N.A.') #substituir por 'N.A.'
dataframe_unico['nomeRegiaoSaude'] = dataframe_unico['nomeRegiaoSaude'].fillna('N.A.') #substituir por 'N.A.'
dataframe_unico['interior/metropolitana'] = dataframe_unico['interior/metropolitana'].fillna('N.A.') #substituir por 'N.A.'
```

Fonte: Autoras

Um outro ponto, é substituir tudo que é ‘NaN’ para 0 em campos numéricos, como é apresentado na Figura 11.

Figura 11 – Transformação da base I

```
# Substituir NaN por 0.0 - Colunas float
dataframe_unico['populacaoTCU2019'] = dataframe_unico['populacaoTCU2019'].fillna(0.0)
dataframe_unico['RecuperadosNovos'] = dataframe_unico['RecuperadosNovos'].fillna(0.0)
dataframe_unico['obitosNovos'] = dataframe_unico['obitosNovos'].fillna(0.0)
dataframe_unico['casosNovos'] = dataframe_unico['casosNovos'].fillna(0.0)
dataframe_unico['emAcompanhamentoNovos'] = dataframe_unico['emAcompanhamentoNovos'].fillna(0.0)
```

Fonte: Autoras

Outra modificação importante a ser feita, é a transformação de campos texto para string. Quando é feita a leitura de uma base em Python, e essa base possui um campo ‘x’ com mais de um tipo diferente de dado em um dataframe, a linguagem automaticamente identifica este campo como ‘object’ (objeto), sabendo disso, para garantir a integridade do dado, é necessário fazer a transformação do campo ‘objeto’ para string, como é apresentado na Figura 12.

Figura 12 – Transformação da base II

```
# Converter colunas específicas para string
dataframe_unico['regiao'] = dataframe_unico['regiao'].astype(str)
dataframe_unico['estado'] = dataframe_unico['estado'].astype(str)
dataframe_unico['municipio'] = dataframe_unico['municipio'].astype(str)
dataframe_unico['coduf'] = dataframe_unico['coduf'].astype(str)
dataframe_unico['codmun'] = dataframe_unico['codmun'].astype(str)
dataframe_unico['codRegiaoSaude'] = dataframe_unico['codRegiaoSaude'].astype(str)
dataframe_unico['nomeRegiaoSaude'] = dataframe_unico['nomeRegiaoSaude'].astype(str)
```

Fonte: Autoras

Nos campos numéricos há também a necessidade de transformação dos dados, no entanto, aqui cabe um adendo: é importante entender a diferença entre um campo ‘int’ de um ‘float’, uma vez que campos int ocupam menos espaço que campos float’s, já que não comportam valores decimais, desta forma, transformar campos numéricos de int para float e vice-versa, incumbiria em uma perda de dados ou até mesmo na ocupação do espaço armazenado desnecessariamente.

Neste caso, conforme ilustrado na Figura 13, foi determinado que a melhor tipagem para os campos seria em inteiro, já que a informação que o campo remete, é de um número

inteiro, exemplo: não há um país que teve 2,5 (dois e meio) pacientes contaminados com o Coronavírus.

Figura 13 – Transformação da base III

```
# Converter colunas específicas de float para inteiro
dataframe_unico['populacaoTCU2019'] = dataframe_unico['populacaoTCU2019'].astype(int)
dataframe_unico['casosAcumulado'] = dataframe_unico['casosAcumulado'].astype(int)
dataframe_unico['casosNovos'] = dataframe_unico['casosNovos'].astype(int)
dataframe_unico['obitosAcumulado'] = dataframe_unico['obitosAcumulado'].astype(int)
dataframe_unico['obitosNovos'] = dataframe_unico['obitosNovos'].astype(int)
dataframe_unico['Recuperadosnovos'] = dataframe_unico['Recuperadosnovos'].astype(int)
dataframe_unico['emAcompanhamentoNovos'] = dataframe_unico['emAcompanhamentoNovos'].astype(int)
```

Fonte: Autoras

Em seguida, foi feita a filtragem e a reorganização do dataframe_unico, a fim de tornar possível a análise de dados por meio de um único dataframe, conforme se verifica na Figura 14.

Figura 14 – Criação da base final

```
In [14]: # Cria o dataframe
dataframe_agrup_unico = pd.DataFrame(dataframe_unico)

# Agrupa pelo estado e semana epidemiológica, somando as colunas numéricas e mantendo a última data de cada grupo
dataframe_agrup_unico = dataframe_agrup_unico.groupby(['semanaEpi', 'regiao', 'estado', 'data', 'populacaoTCU2019']).agg({
    'casosNovos': 'sum',
    'casosAcumulado': 'last',
    'obitosNovos': 'sum',
    'obitosAcumulado': 'last',
    'Recuperadosnovos': 'sum',
    'emAcompanhamentoNovos': 'sum'
}).reset_index()

# Exibe as primeiras linhas do DataFrame combinado:
display(HTML(dataframe_agrup_unico.head(53).to_html()))
```

	semanaEpi	regiao	estado	data	populacaoTCU2019	casosNovos	casosAcumulado	obitosNovos	obitosAcumulado	Recuperadosnovos	emAcompanhamentoNovos
0	1	Brasil	Brasil	2021-01-03	210147125	17341	7733746	293	196018	6769420	
1	1	Brasil	Brasil	2021-01-04	210147125	20006	7753752	543	196561	6813008	
2	1	Brasil	Brasil	2021-01-05	210147125	56648	7810400	1171	197732	6875230	
3	1	Brasil	Brasil	2021-01-06	210147125	63430	7873830	1242	198974	6963407	
4	1	Brasil	Brasil	2021-01-07	210147125	87843	7961673	1524	200498	7036530	
5	1	Brasil	Brasil	2021-01-08	210147125	52035	8013708	962	201460	7096931	
6	1	Brasil	Brasil	2021-01-09	210147125	62290	8075998	1171	202631	7114474	

Fonte: Autoras

4.4. CARREGAMENTO DAS BASES

Por fim, após o tratamento da base, é necessário realizar o carregamento do dataframe para algum diretório local, podendo ser o diretório inicial ou outro, para que o dado seja armazenado corretamente e sirva como objeto de análise por meio de visuais e métricas específicas.

De acordo com a Figura 15, a exportação da base tratada corresponde à etapa de Carregamento no processo ETL, quando os dados consolidados são transportados para um ambiente de análise, conforme descrito por Singh e Singh (2016) e AWS Amazon (2024). Essa estruturação garante acessibilidade e desempenho nas consultas analíticas subsequentes

Figura 15 – Exportação da base de dados com Python

```
# Exporta o dataframe em CSV para um diretório específico no Jupyter (servirá como backup)
dataframe_agrup_unico.to_csv(r'C:\Users\Sabrina\Database_covid\Database_export\dataframe_agrup_unico.csv', index=False)

## Exportar o dataframe em CSV para uma pasta no :C da máquina Local

# Diretório de destino no C:
diretorio_destino = r'C:\TCC\export'

# Caminho completo do arquivo
caminho_arquivo = os.path.join(diretorio_destino, 'dataframe_agrup_unico.csv')

# Exporta o DataFrame para o arquivo CSV
dataframe_agrup_unico.to_csv(caminho_arquivo, index=False)


print(f'Arquivo exportado com sucesso para {caminho_arquivo}')
```

Arquivo exportado com sucesso para C:\TCC\export\dataframe_agrup_unico.csv

Fonte: Autoras

Por fim, a exportação da base de dados foi feita em formato CSV em um diretório local, como sugere a Figura 16, permitindo a criação de um relatório por meio de uma ferramenta de dataviz. A escolhida para o projeto foi o Power BI.

Figura 16 – 'dataframe_agrup_unico' salvo no diretório 'C:\TCC\export'



Fonte: Autoras

4.5. CRIAÇÃO DOS VISUAIS

Ao ser feita a exportação da base de dados já tratada, foram criados visuais, cuja finalidade é tornar possível o entendimento dos dados acerca do que foi a COVID-19 no Brasil.

A criação dos visuais foi realizada no Microsoft Power BI, conforme apresentado no capítulo de Materiais e Métodos, sendo o produto final da aplicação dos processos ETL e KDD descritos anteriormente. Essa etapa reflete a fase de interpretação e avaliação do ciclo KDD (Fayyad et al., 1996; Freitas, 2000), em que os resultados são convertidos em conhecimento acessível e aplicável.

Na aba Overview foram inseridos visuais que trouxessem informações gerais em relação à situação mais atual do Coronavírus e seu impacto no Brasil. Tais visuais foram criados com o objetivo de assemelharem-se ao Painel Geral, desenvolvido pelo Ministério da Saúde (Figura 5, pg. 25).

Figura 17 – Dashboard – aba Overview



Fonte: Autoras

No primeiro quadro de informações - como pode ser observado na Figura 17 -, “Casos Confirmados”, da esquerda para a direita, observa-se a quantidade de casos acumulados do início da pandemia (desde 2020) até os dias de hoje, a quantidade de casos novos da doença (referente à data “26/04/2025”, encontrada no canto superior direito do dashboard – correspondendo à 17ª semana epidemiológica) e o número de incidência (por 100mil habitantes). Cabe aqui esclarecer, que o número de incidentes, é uma medida muito utilizada no campo da saúde, visando entender a proporção de infectados em um grupo de pessoas. Neste caso, a medida foi calculada por meio da seguinte regra:

$$\text{Taxa de Incidência} = \frac{\text{Soma dos casos acumulados}}{\text{Soma da população}} \times 100000$$

Para que tal medida seja recriada no dashboard, será necessário seguir o padrão abaixo:

Incidencia = DIVIDE(
 SUM(dataframe_agrup_unico[casosAcumulado]),
 *SUM(dataframe_agrup_unico[populacaoTCU2019]),0) * 100000*

No quadro ao lado, “Óbitos Confirmados”, é mostrado o número de óbitos acumulados, óbitos novos, correspondendo à 17ª semana epidemiológica, e os indicadores de mortalidade e letalidade (%). O indicador de mortalidade, busca evidenciar a frequência de mortes em uma determinada população. Sendo assim, o cálculo para a taxa de mortalidade se dá por:

$$\text{Taxa de Mortalidade} = \frac{\text{Número de óbitos em um período}}{\text{População total no mesmo período}} \times k$$

Sendo k um fator multiplicador usado para facilitar a interpretação (ex.: 1.000, 10.000 ou 100.000 habitantes).

Desta forma, observa-se uma representação em linguagem DAX:

TaxaMortalidade_MaxData =
 VAR DataMax = MAX(dataframe_agrup_unico[data])
 VAR ObitosAcumuladosMaxData =
 CALCULATE(

```

SUM(dataframe_agrup_unico[ObitosAcumulado]),
dataframe_agrup_unico[data] = DataMax)
VAR PopulacaoMaxData =
CALCULATE(
SUM(dataframe_agrup_unico[PopulacaoTCU2019]),
dataframe_agrup_unico[data] = DataMax)
RETURN
DIVIDE(ObitosAcumuladosMaxData * 100000, PopulacaoMaxData, 0)

```

Por fim, a taxa de letalidade: que busca medir a gravidade da doença entre os infectados, ou seja:

$$\text{Taxa de Letalidade (\%)} = \frac{\text{Óbitos acumulados}}{\text{Casos acumulados}} \times 100$$

Que em linguagem DAX, fica:

```

TaxaLetalidade = DIVIDE(
SUM(dataframe_agrup_unico[obitosAcumulado]),
SUM(dataframe_agrup_unico[casosAcumulado]), 0*100

```

Por fim, há também uma tabela que reúne de forma sucinta, como ilustrado na Figura 18, as informações gerais do estado da doença no país, trazendo a quantidade de casos acumulado por região/estado, assim como também o número de óbitos acumulado, a incidência e a mortalidade por 100mil habitantes, e a população total.

O uso de indicadores como incidência e mortalidade segue as boas práticas de visualização recomendadas pela literatura de Business Intelligence, que apontam o

papel dos dashboards na tradução de grandes volumes de dados em informações compreensíveis (Microsoft, 2023; Dong, Du e Gardner, 2020).

Figura 18 – Aba Overview – Tabela Síntese de casos, óbitos, incidência e mortalidade

Região / Estado	Casos acumulado	Óbitos acumulado	Incidência/100mil hab.	Mortalidade/100mil hab	População total
Brasil					
Brasil	39.300.196	716.569	18.701,3	340,98	210.147.125
Sudeste					
SP	6.956.972	185.212	15.150,5	403,34	45.919.049
MG	4.373.515	67.187	20.660,2	317,39	21.168.791
RJ	2.996.066	78.454	17.353,5	454,41	17.264.943
ES	1.402.780	15.258	34.906,7	379,68	4.018.650
Nordeste					
BA	1.854.075	32.145	12.466,0	216,13	14.873.064
PE	1.244.056	23.300	13.017,1	243,80	9.557.071
CE	1.536.345	28.215	16.823,6	308,97	9.132.078
MA	503.001	11.109	7.109,4	157,01	7.075.181
PB	732.336	10.748	18.225,8	267,49	4.018.127
RN	605.269	9.351	17.259,6	266,65	3.506.853
AL	351.025	7.380	10.518,1	221,13	3.337.357
PI	439.260	8.449	13.419,8	258,12	3.273.227
SE	368.821	6.592	16.044,8	286,77	2.298.696
Sul					
PR	3.041.284	47.082	26.598,7	411,77	11.433.957
RS	3.166.390	43.256	27.830,9	380,20	11.377.239
SC	2.102.620	23.250	29.346,6	324,50	7.164.788


Fonte: Autoras

Já na Figura 19, apresenta a aba “Casos Novos e Acumulados”, que traz uma visão acumulada por ano dos incidentes da doença na população brasileira. O foco principal, é prover uma visão macro do impacto da doença, através de um comparativo quantitativo do impacto dos casos da doença por ano, região e estado.

O primeiro quadro traz o comparativo da quantidade de casos novos por ano, sendo o eixo X a quantidade de casos novos e o eixo Y a semana epidemiológica agrupada por ano.

Já no gráfico abaixo – ainda na mesma aba –, é possível ter a visão cronológica da evolução dos casos acumulados no Brasil.


Figura 19 – Dashboard – aba Casos Novos e Acumulados



Fonte: Autoras

Em seguida, a Figura 20 apresenta a aba “Óbitos Novos e Acumulados”, que promove uma visão focada no contexto das mortes pela Covid-19, por meio de uma relação entre ano/semana epidemiológica e por estado/região.


Figura 20 – Dashboard – aba Óbitos Novos e Acumulados



Fonte: Autoras

Além disso, caso seja do desejo do usuário, é concebível também ter uma visão focada em um estado específico e/ou por ano, como apresenta a Figura 21.

Figura 21 21 – Dashboard – Casos novos e acumulado de São Paulo



Fonte: Autoras

Dessa forma, o dashboard “Painel Coronavírus Brasil” evidencia a integração entre teoria e prática, demonstrando como as etapas de ETL e KDD, fundamentadas por autores como Kimball (2011) e Steiner et al. (2006), permitem gerar informações precisas e úteis à gestão pública e ao combate à desinformação (Galhardi et al., 2022; Zarocostas, 2020).

4.6. VISUALIZAÇÃO DE DADOS COMO APOIO À VALIDAÇÃO DA INFORMAÇÃO

Embora o presente trabalho não tenha como objetivo direto a eliminação da disseminação de fake news, os resultados obtidos demonstram que a análise estruturada de dados pode atuar como um importante instrumento de prevenção e validação de informações. A partir do uso de bases oficiais, como o DATASUS, e da aplicação dos processos de ETL e KDD, foi possível construir uma visão consistente e verificável da evolução da COVID-19 no Brasil.

O dashboard desenvolvido oferece uma visão realista dos dados, ao apresentar indicadores epidemiológicos consolidados como, casos confirmados, óbitos, incidência e mortalidade, organizados de forma clara, transparente e comparável ao longo do tempo e entre regiões. Essa visualização possibilita que o usuário confronte

informações divulgadas em mídias tradicionais ou digitais com dados oficiais, reduzindo interpretações distorcidas e auxiliando na identificação de conteúdos inconsistentes ou sensacionalistas.

Além disso, a possibilidade de filtragem por ano, estado e região contribui para contextualizar os dados, evitando generalizações indevidas, frequentemente presentes em notícias falsas. Ao permitir que o usuário explore diferentes recortes temporais e geográficos, o dashboard favorece uma compreensão mais crítica da realidade epidemiológica, fortalecendo o papel da análise de dados como suporte à leitura consciente da informação.

Dessa forma, a função do dashboard não se limita à apresentação visual dos dados, mas se estende à validação informacional, ao oferecer indicadores confiáveis que sustentam uma interpretação baseada em evidências. Assim, o uso de dados estruturados e visualizados de maneira objetiva se mostra um recurso relevante no enfrentamento indireto das fake news, ao promover transparência, acessibilidade e confiança nas informações divulgadas sobre a COVID-19.

5. CONSIDERAÇÕES FINAIS

A presente pesquisa exploratória abordou a questão da Extração, Transformação e Carregamento de Dados como Recurso para Validação de Informações: Um estudo de caso dos dados disponibilizados por meio do DATASUS. Neste trabalho, as autoras buscaram esboçar alguns tópicos de relevante questão quanto às informações disseminadas durante o período da COVID-19 no Brasil e a maneira como estas eram consumidas e validadas pelo público em geral.

Primeiramente, foi desenvolvido um guia de exploração de dados que visa o entendimento dos dados por meio dos processos ETL e KDD, fazendo uso da extração, transformação e carregamento dos dados, permitindo uma análise acurada e concisa das informações, que tornou-se possível a consolidação deste conhecimento em visuais, por meio de ferramentas de Dataviz como o Power BI, a fim de compreender os efeitos da doença em território nacional, servindo também como um modelo de análise para outros temas, como por exemplo – fazendo uso somente de dados públicos – , Saneamento Básico, Habitação, Educação, Economia e Finanças, etc.

Desta forma, obteve-se a partir dessa esteira de processos o dashboard Painel Coronavírus Brasil, contendo informações de casos e óbitos confirmados assim como casos e óbitos novos, podendo ser filtrados por ano, região e estado. Como também, uma visão macro da saúde pública do Brasil em relação à doença, por meio de indicadores como mortalidade e incidência da doença. Servindo como uma ferramenta de validação das informações quando comparadas às notícias divulgadas nas mídias tradicionais e digitais.

Frente a isso, pode-se perceber que a pandemia evidenciou a importância de dados estruturados e acessíveis para enfrentar desafios sanitários globais, tornando-se essencial discutir como a análise de dados pode ser utilizada como uma ferramenta eficaz contra a disseminação de fake news. A organização e a interpretação correta dos dados são fundamentais para diferenciar informações verificadas de conteúdos duvidosos ou manipulados.

REFERÊNCIAS

Agrawal, R., Mehta, M., Shafer, J. C., Srikant, R., Arning, A., and Bollinger, T. (1996). **The quest data mining system**. In KDD, volume 96, pages 244–249.

ALLCOTT, H.; GENTZKOW, M. **Social media and fake news in the 2016 election**. *Journal of Economic Perspectives*, v. 31, n. 2, p. 211-236, 2017.

ANACONDA. About us. Disponível em: <<https://www.anaconda.com/about-us>>. Acesso em: 27 abr. 2025.

ANACONDA. **Anaconda Documentation**. 2025. Disponível em: <<https://docs.anaconda.com/>>. Acesso em: 24 ago. 2025.

AWS AMAZON. **O que é ETL?** Disponível em: <<https://aws.amazon.com/pt/what-is/etl/>>. Acesso em: 15 dez. 2024.

BASTOS, L. S. et al. **Limitations of using the DATASUS database as a primary source for epidemiological studies in Brazil**. *Revista de Saúde Pública*, v. 57, p. 3-10, 2023. Disponível em: <<https://www.scielo.br/j/rsp/a/HLgDkhXWj6Ct5i3FfPvZr5x/>> Acesso em: 20 de ago. 2025.

BIRCK, L. M. et al. **Real-world use of biologic and targeted synthetic DMARDs for rheumatoid arthritis in Brazil: analysis of DATASUS data**. *Scientific Reports*, v. 13, n. 1, 2023. Acesso em: 20 ago. 2025.

BRASIL. **Ministério da Saúde. Painel Coronavírus**. Disponível em: <<https://covid.saude.gov.br/>>. Acesso em: 15 dez. 2024.

BRITO, Sávio Breno Pires; BRAGA, Isaque Oliveira; CUNHA, Carolina Coelho; PALÁCIO, Maria Augusta Vasconcelos; TAKENAMI, Iukary. **Pandemia da COVID-19: o maior desafio do século XXI**. *Vigilância Sanitária em Debate*, Rio de Janeiro, v. 8, n.2, p. 54-63, abr./jun. 2020. INCQS-FIOCRUZ. Disponível em: <<https://doi.org/10.22239/2317-269X.01531>>. Acesso em: 14 abr. 2025.

CASERO-RIPOLLÉS, A. **O Impacto da Covid-19 no Jornalismo: Um Conjunto de Transformações em Cinco Domínios**. Departamento de Ciências da Comunicação, Facultad de Ciencias Humanas y Sociales, Universitat Jaume I de Castelló, Castelló, Espanha, 2020. Acesso em: 15 fev. 2025.

CASERO-RIPOLLÉS, A. **O Impacto da Covid-19 no Jornalismo: Um Conjunto de Transformações em Cinco Domínios**. Departamento de Ciências da Comunicação, Facultad de Ciencias Humanas y Sociales, Universitat Jaume I de Castelló, Castelló, Espanha, 2020. Disponível em: <<https://seer.upf.br/index.php/rbca/article/view/12372>> Acesso em: 15 fev. 2025.

CARDOSO, R. L.; ALMEIDA, J. M.; SANTOS, F. R. **Governança de dados e LGPD: implicações para processos de ETL**. *Revista Brasileira de Computação Aplicada*, v. 13, n. 2, p. 45-60, 2021.

CHEN, Q. et al. **Managing misinformation in the COVID-19 era.** *BMC Medical Informatics and Decision Making*, v. 20, n. 1, p. 1-6, 2020. Disponível em: <<https://bmcmmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-020-01156-3>>. Acesso em: 8 abr.2025.

DONG, E.; DU, H.; GARDNER, L. **An interactive web-based dashboard to track COVID-19 in real time.** *The Lancet Infectious Diseases*, v. 20, n. 5, p. 533-534, 2020. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC7159018/>>. Acesso em: 05 abr. 2025.

FAYYAD, U. M.; PIATETSKY-SHAPIO, G.; SMYTH, P.; UTHURUSAMY, R. **Advances in Knowledge Discovery & Data Mining.** 1 ed. American Association for Artificial Intelligence, Menlo Park, Califórnia, 1996. 611 folhas.

FREITAS, A. A. **Uma Introdução a Data Mining.** Informática Brasileira em Análise, Centro de Estudos e Sistemas Avançados do Recife (C.E.S.A.R.), Recife, Pe, ano II, n. 32, 2000.

FUNDAÇÃO OSWALDO CRUZ (FIOCRUZ). **Relatório sobre desinformação e fake news durante a pandemia de COVID-19 no Brasil.** Fiocruz, 2020. Disponível em: <<https://www.fiocruz.br>>. Acesso em: 8 mar. 2025.

GALHARDI, Cláudia Pereira; FREIRE, Neyson Pinheiro; FAGUNDES, Maria Clara Marques; MINAYO, Maria Cecília de Souza; CUNHA, Isabel Cristina Kowal Olm. **Fake news e hesitação vacinal no contexto da pandemia da COVID-19 no Brasil.** *Ciência & Saúde Coletiva*, v. 5, pág. 1849-1858, 2022. Disponível em: <<https://doi.org/10.1590/1413-81232022275.24092021>>. Acesso em: 16 mar. 2025.

GIL, A. C. Métodos e técnicas de pesquisa social. 6. ed. São Paulo: Atlas, 2008. GOLFARELLI, M.; RIZZI, S. **Data Warehouse Design: Modern Principles and Methodologies.** New York: McGraw-Hill, 2009. Acesso em: 15 ago. 2025.

HASSAN, Syed Adeel; SHEIKH, Fahad N.; JAMAL, Somia; EZEH, Jude K.; AKHTAR, Ali. **Coronavirus (COVID-19): A Review of Clinical Features, Diagnosis, and Treatment.** *Cureus*, [s.l.], v. 12, n. 3, p.e7355, 2020. Disponível em: <https://assets.cureus.com/uploads/review_article/pdf/27924/1612429779-1612429775-20210204-18590-1qlin8.pdf>. Acesso em: 21 mar. 2024.

HE, Feng; DENG, Yu; LI, Weina. **Coronavirus disease 2019: What we know?** *Journal of Medical Virology*, [s.l.], v. 92, n. 7, p. 719-725, 2020. Wiley. Disponível em: <<https://onlinelibrary.wiley.com/doi/full/10.1002/jmv.25766>>. Acesso em: 20 mar. 2024.

HEISLER, G. V.; ASSUNÇÃO, J. V. C. **Aplicação do Processo de KDD aos Dados da COVID-19: Um Estudo de Caso no Rio Grande do Sul.** Universidade Federal de Santa Maria, 2024.

HEISLER, G. V. **Repositório de código e resultados do estudo de KDD aplicado à COVID-19.** Disponível em: <https://github.com/gvheisler/KDD-COVID-19>. Acesso em: 24 ago. 2025.

INMON, W. H. **Building the Data Warehouse**. 4. ed. New York: Wiley, 2005.
KIMBALL, R. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3. ed. New Jersey: Wiley, 2011. Acesso em: 23 ago. 2025.

KIMBALL, R.; CASERTA, J. **The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data**. Indianapolis: Wiley, 2011. Disponível em: <<https://www.wiley.com/en-us/The+Data+Warehouse+ETL+Toolkit-p-9780764567575>>. Acesso em: 23 ago. 2025.

LORENZETTI, L.; VICENTINI, F. **Fake news e saúde pública: impactos da desinformação na pandemia de Covid-19 no Brasil**. Revista Eletrônica de Comunicação, Informação & Inovação em Saúde, v. 15, 2021. DOI: 10.29397/reciis.v15i1.2362. Acesso em: 12 fev. 2025.

LIMA, A. C. et al. **DATASUS: o uso dos Sistemas de Informação na Saúde Pública**. Refas - Revista Fatec Zona Sul, v. 1, n. 3, p. 16–31, 2015. Disponível em: <<https://revistarefas.com.br/index.php/RevFATECZS/article/view/27>>. Acesso em: 24 mai. 2025.

MALIK, Yashpal Singh; KUMAR, Naveen; SIRCAR, Shubhankar; KAUSHIK, Rahul; BHAT, Sudipta; DHAMA, Kuldeep; et al. **Coronavirus Disease Pandemic (COVID-19): Challenges and a Global Perspective**. *Pathogens*, Basel, v. 9, n. 7, p. 519, 2020. MDPI. Disponível em: <<https://www.mdpi.com/2076-0817/9/7/519>>. Acesso em: 21 mar. 2024.

MICROSOFT. **O que é o Power BI?**. 2023. Disponível em: <<https://learn.microsoft.com/pt-br/power-bi/fundamentals/power-bi-overview>>. Acesso em: 24 ago. 2025.

MINAYO, M. C. S. **O desafio do conhecimento: pesquisa qualitativa em saúde**. 14. ed. São Paulo: Hucitec, 2017. Disponível em: <<https://www.scielo.br/j/csc/a/FgpDFKSpjsybVGMj4QK6Ssv/>>. Acesso em: 14 dez. 2025.

MINISTÉRIO DA SAÚDE. **Ministério da Saúde apresenta novo protocolo para uso da cloroquina**. Agência Brasil, 20 maio 2020. Disponível em: <<https://agenciabrasil.ebc.com.br/saude/noticia/2020-05/ministerio-saude-apresenta-novo-protocolo-para-uso-cloroquina>>. Acesso em: 06 abr .2025.

MARCONI, M. A.; LAKATOS, E. M. **Fundamentos de metodologia científica**. 8. ed. São Paulo: Atlas, 2017.

OLIVEIRA, Thaise Villarim de. **Aspectos gerais da pandemia de COVID-19**. Revista Brasileira de Saúde Materno Infantil, Recife, v. 21, supl. 1, p. S47-S64, fev. 2021. Disponível em: <<http://dx.doi.org/10.1590/1806-9304202100S100003>>. Acesso em: 16 fev. 2025.

OPAS – ORGANIZAÇÃO PAN-AMERICANA DA SAÚDE. **OMS caracteriza a COVID-19 como uma pandemia.** 2020. Disponível em: <<https://www.paho.org/pt/news/11-3-2020-who-characterizes-covid-19-pandemic>>. Acesso em: 16 mar. 2025.

ORELLANA, Jesem Douglas Yamall; CUNHA, Geraldo Marcelo da; MARRERO, Lihsieh; MOREIRA, Ronaldo Ismerio; LEITE, Iuri da Costa; HORTA, Bernardo Lessa. **Excesso de mortes durante a pandemia de COVID-19: subnotificação e desigualdades regionais no Brasil.** Cadernos de Saúde Pública, Rio de Janeiro, v. 36, n. 1, e00259120, 2020. Disponível em: SciELO Brasil. Acesso em: 25 maio 2025.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). **Declaração de pandemia por COVID-19.** OMS, 2020. Disponível em: <<https://www.who.int>>. Acesso em: 8 mar. 2025.

ORGANIZAÇÃO PAN-AMERICANA DA SAÚDE (OPAS). **Sistemas de informação em tempos de pandemia.** OPAS, 2020. Disponível em: <<https://www.paho.org>>. Acesso em: 9 mar. 2025.

PURI, N. et al. **Social media and vaccine hesitancy: new updates for the era of COVID-19 and globalized infectious diseases.** Human Vaccines & Immunotherapeutics, v. 16, n. 11, p. 2586-2593, 2020. Disponível em: <<https://www.tandfonline.com/doi/full/10.1080/21645515.2020.1780846>>. Acesso em: 8 abr. 2025.

RECUERO, R.; SOARES, F. B.; GRUZD, A. **Hyperpartisanship, Disinformation and Political Conversations on Twitter: The Brazilian Presidential Election of 2018.** Social Media + Society, v. 6, n. 2, 2020. DOI: 10.1177/2056305120924805. Acesso em: 9 fev. 2025.

RIBEIRO, Haroldo et al. **Desigualdades regionais na vigilância epidemiológica da COVID-19 no Brasil.** Cadernos de Saúde Pública, Rio de Janeiro, v. 36, n. 9, e00181720, 2020. Disponível em: <<https://www.scielo.br/j/csp/a/gd7tqc7pScNRZnyMWvNkgpR/?lang=pt>>. Acesso em: 04 maio 2025.

RIBEIRO, L. C.; BERNARDES, A. T.; MOREIRA, J. P. **Transparência e governança dos dados de COVID-19 no Brasil: o papel do DATASUS e do Painel Coronavírus.** Revista Panamericana de Salud Pública, v. 45, e110, 2021. Disponível em: <<https://doi.org/10.26633/RPSP.2021.110>>. Acesso em: 23 ago. 2025.

SCHRARSTZHAUPT, I. N. et al. **Painéis de monitoramento interativos da pandemia de COVID-19 no mundo com o uso de dados abertos antecipando ondas da doença no Brasil.** Revista Brasileira de Epidemiologia, v. 27, e240004, 2024. Disponível em: <<https://scielosp.org/article/rbepid/2024.v27/e240004/pt/>>. Acesso em: 1 jun. 2025.

SILVA, J. F.; SANTOS, M. A.; OLIVEIRA, R. P. **Dados governamentais abertos sobre a COVID-19 no Brasil: análise da oferta e da demanda por informação pública.** Revista Em Questão, v. 28, n. 3, p. 23-45, 2022. Disponível em:

<<https://www.scielo.br/j/emquestao/a/q5dXB3wjnQ9KdJtpZ6NrVVj/>>. Acesso em: 8 abr. 2025.

SINGHAL, Tanu. **A Review of Coronavirus Disease-2019 (COVID-19)**. Indian Journal of Pediatrics, [s.l.], v. 87, p. 281-286, 2020. Springer. Disponível em: <<https://link.springer.com/article/10.1007/s12098-020-03263-6>>. Acesso em: 19 mar. 2024.

SINGH, S.; SINGH, N. **Big Data Analytics: ETL Process for Structured and Unstructured Data**. International Journal of Advanced Research in Computer Science, v. 7, n. 1, p. 23-28, 2016. Disponível em: <<https://ijarcs.info/index.php/ijarcs/article/view/2527>>. Acesso em: 24 ago. 2025.

SOUSA, Aline Faria de. STADULNI, Andreia Rodrigues Parnoff. COSTA, Lucas Bevilacqua Alves da. **Uso De Dados Do Departamento De Informática Do Sistema Único De Saúde (DATASUS) Em Pesquisas Científicas**. Revista Científica Multidisciplinar Núcleo Do Conhecimento. Ano 06, Ed. 04, Vol. 11, pp. 171-185. Abril de 2021. ISSN: 2448-0959. Disponível em: <<https://www.nucleodoconhecimento.com.br/saude/saude-datasus>>. Acesso em: 25 mai. 2025.

SOUZA, Alex Sandro Rolland; AMORIM, Melania Maria Ramos; MELO, Adriana Suely de Oliveira; DELGADO, Alexandre Magno; FLORENCIO, Anna Catharina Magliano Carneiro da Cunha; SOUZA, Bruno. **ETL (extração, transformação e carga): simplificando o processo de análise de dados ELT**. Medium, 25 out. 2023. Disponível em: <<https://medium.com/blog-do-zouza/etl-extra%C3%A7%C3%A3o-transforma%C3%A7%C3%A3o-e-carga-simplificando-o-processo-de-an%C3%A1lise-de-dados-elt-631e3a56c8bb>>. Acesso em: 15 dez. 2024.

SOUZA, C. D. F. et al. **Análise epidemiológica da pandemia de COVID-19 no Brasil e o papel do Painel Coronavírus do Ministério da Saúde**. Ciência & Saúde Coletiva, v. 26, n. 6, p. 2447-2454, 2021. Disponível em: <<https://www.scielo.br/j/csc/a/3W9Mnsm7RnD8p7JZnXGpK6j/>>. Acesso em: 24 ago. 2025.

STEINER, M. T. A. et al. **Abordagem de um problema médico por meio do processo de KDD com ênfase à análise exploratória dos dados**. Gestão & Produção, v. 13, n. 2, p. 325–337, 2006.

TURBAN, E.; SHARDA, R.; ARONSON, J. E.; KING, D. **Business Intelligence: A Managerial Approach**. 2. ed. Upper Saddle River: Prentice Hall, 2011.

VERGARA, S. C. **Projetos e relatórios de pesquisa em administração**. 11. ed. São Paulo: Atlas, 2009.

WARDLE, C.; DERA KHSHAN, H. **Information disorder: Toward an interdisciplinary framework for research and policymaking**. Council of Europe Report, 2017. Disponível em: <<https://rm.coe.int/information-disorder-toward-an-interdisciplinary-framework-for-research/168076277c>>. Acesso em: 8 fev. 2025.

ZAROCOSTAS, J. **How to fight an infodemic**. The Lancet, v. 395, n. 10225, p. 676, 2020. Disponível em: <[https://www.thelancet.com/journals/lancet/article/PIIS0140-6736\(20\)30461-X/](https://www.thelancet.com/journals/lancet/article/PIIS0140-6736(20)30461-X/)>. Acesso em: 05 abr. 2025.